

Exploratory Data Analysis para PiSA Farmacéutica

Jose Angel Govea Garcia¹, Daniel Alberto Sánchez Fortiz¹ and Diego Vértiz Padilla¹

¹ Tecnológico de Monterrey, Escuela de Ingeniería y Ciencias, Campus Guadalajara, México

Reception date of the manuscript: 09/03/2025

Acceptance date of the manuscript: -/-/-
Publication date: -/-/--

Abstract— Este trabajo presenta un análisis exploratorio de datos (EDA) realizado para PiSA Farmacéutica, específicamente sobre los datos de sensores de la máquina sopladora utilizada en la producción de Electrolit. La problemática se centra en la reducción de la vida útil de dicha máquina, que en lugar de operar por un año, solo lo hace por dos o tres meses. La hipótesis se basa en la variabilidad extrema de las temperaturas registradas por múltiples sensores. Se procesaron y analizaron datasets masivos de más de 45 millones de registros, utilizando técnicas de filtrado, limpieza y detección de anomalías a través del algoritmo KNN de la librería PyOD. Se identificaron patrones de anomalías coincidentes en múltiples variables de temperatura que podrían estar afectando el desempeño de la máquina, acercándonos a validar nuestra hipótesis inicial.

Keywords— Análisis exploratorio de datos, sensores industriales, detección de anomalías, industria farmacéutica, mantenimiento predictivo

I. Introducción

PiSA Farmacéutica es una empresa mexicana establecida internacionalmente. La fábrica cuenta con más de 1,500 marcas de medicamentos integradas en 17 líneas de especialidad y 14 plantas de producción en México. Su producto más conocido a nivel mundial es el suero *Electrolit*, el cual se envasa en botellas fabricadas mediante una máquina sopladora.

Esta máquina es crítica para el proceso, ya que asegura que las botellas sean infladas adecuadamente. Sin embargo, se ha detectado que su vida útil se ha reducido drásticamente de un año a solo dos o tres meses, lo cual genera pérdidas significativas para la empresa.

II. PROBLEMA Y MOTIVACIÓN

La sopladora cuenta con más de 100 sensores que miden variables clave: temperatura, presión, corriente, ángulo y velocidad. Se sospecha que la variabilidad extrema en las temperaturas de operación podría estar afectando el desempeño y reduciendo la vida útil de la máquina.

III. HIPÓTESIS

Nuestra hipótesis es que las fluctuaciones en las temperaturas registradas por los sensores están generando un estrés térmico adicional en los componentes de la sopladora y la preforma, lo que disminuye su vida útil.

Contact data: Daniel Alberto Sánchez Fortiz, a01255138@tec.mx

IV. METODOLOGÍA

a. Datos

Se analizaron dos archivos proporcionados por PiSA, cada uno con un tamaño aproximado de 1.8 GB, correspondientes a los meses de noviembre de 2024 y enero de 2025. Cada dataset contiene alrededor de 45 millones de registros en formato .parquet.

b. Procesamiento de los Datos

Los datos se procesaron mediante la librería pandas en Python. Se dividieron en bloques (*chunks*) de 100,000 registros y se consolidaron en archivos esv diarios para facilitar el análisis.

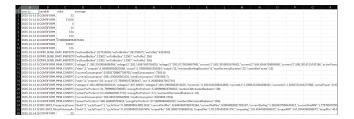


Fig. 1: Dataset filtrado a un solo dia.

Los datos crudos contenían cuatro columnas: user_ts, variable, valor y mensaje. Se realizó un pivoteo de los datos para transformar las variables de temperatura en columnas independientes.



Fig. 2: Dataset pivoteado.

c. Selección de Variables

Debido a la alta cantidad de valores nulos, se seleccionaron las variables con mayor disponibilidad de datos, utilizando el cuartil 80. Se identificaron de 10 a 13 variables clave por día, entre ellas:

- energyPerPreform_CurrentPreform NeckFinishTemperature.0
- energyPerPreform_CurrentPreform TemperatureOvenInfeed.0
- numberOfActivatedRadiators_CurrentPreform NeckFinishTemperature.0
- 4. powerPerPreform_CurrentPreform NeckFinishTemperature.0
- value_ActualTemperatureCoolingCircuit2.0
- 6. value_CurrentPreformTemperature OvenInfeed.0

d. Detección de Anomalías

Se utilizó el modelo KNN de la librería PyOD para detectar anomalías en las series de tiempo. Se ajustaron los parámetros n_neighbors=20 y contamination=0.0025 para obtener un balance entre la detección y la reducción de falsos positivos.

V. RESULTADOS

Como ejemplo, tomamos el día 15 de enero de 2025. Éstas fueron las gráficas con las anomalías detectadas:

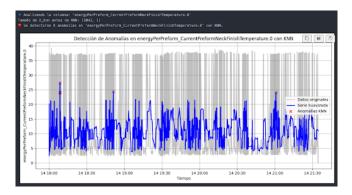


Fig. 3

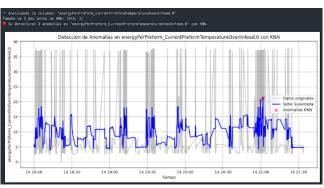


Fig. 4

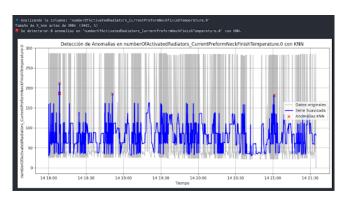


Fig. 5

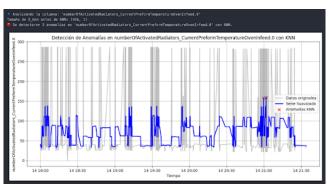


Fig. 6

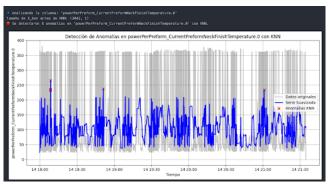


Fig. 7



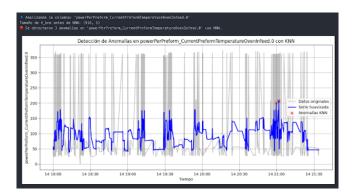


Fig. 8

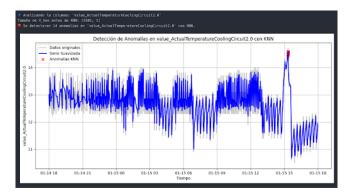


Fig. 9

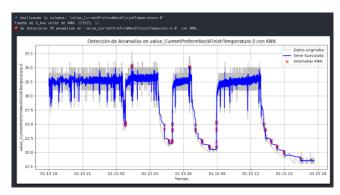


Fig. 10

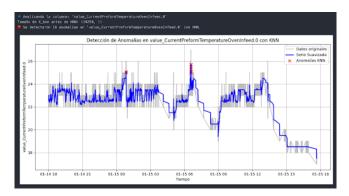


Fig. 11

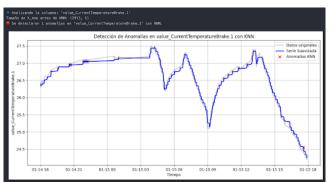


Fig. 12

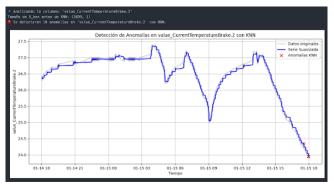


Fig. 13

El análisis reveló múltiples anomalías que coincidieron temporalmente en diferentes variables de temperatura. Algunos ejemplos son:

• 2025-01-14 18:08:32: Anomalías en:
energyPerPreform_CurrentPreform
NeckFinishTemperature.0,
numberOfActivatedRadiators_CurrentPreform
NeckFinishTemperature.0 y
powerPerPreform_CurrentPreform
NeckFinishTemperature.0.

• 2025-01-14 20:59:48: Anomalías en:
energyPerPreform_CurrentPreform
TemperatureOvenInfeed.0,
numberOfActivatedRadiators_CurrentPreform
TemperatureOvenInfeed.0 y
powerPerPreform_CurrentPreform
TemperatureOvenInfeed.0.

VI. CONCLUSIONES

El análisis exploratorio de datos realizado permitió identificar patrones de anomalías, sabiendo que no podemos concluir que con una sola anomalía se puede crear el error en la máquina. Pero con esta lista que nos dice que hay diferentes anomalías al mismo tiempo podemos acercarnos a probar la hipótesis.